

3번 EDA

주자 상황 및 경기 중요도 변수 EDA

1. 분석 대상

이번 EDA에서는 현재 투구 직전의 주자 배치와 경기 상황의 중요도를 나타내는 다음 8개 변수를 분석한다.

구분	컬럼	공식 의미
주자 여부	runner_on_1b	1루 주자 여부
주자 여부	runner_on_2b	2루 주자 여부
주자 여부	runner_on_3b	3루 주자 여부
주자 수	num_runners_on	현재 출루해 있는 주자 수
주자 조합	base_state	현재 각 베이스의 주자 배치
기대 승률	home_win_expectancy	홈팀 기대 승률
기대 승률	away_win_expectancy	원정팀 기대 승률
상황 중요도	li	현재 투구 상황의 중요도

모든 변수는 현재 투구가 이루어지기 직전의 상태를 나타낸다. 따라서 현재 투구 이후의 결과는 포함하지 않는다.

2. 야구 초보자용 컬럼 설명

컬럼	쉬운 설명	값의 예시와 해석
runner_on_1b	현재 1루에 주자가 있는지 나타냄	1 이면 1루에 주자가 있고, 0 이면 없음(아래도 동일)
runner_on_2b	현재 2루에 주자가 있는지 나타냄	2루 주자는 안타 하나로 득점할 가능성이 높은 득점권 주자
runner_on_3b	현재 3루에 주자가 있는지 나타냄	3루 주자는 희생플라이·폭투 등으로도 득점할 수 있어 심리적 압박이 큼
num_runners_on	현재 출루한 전체 주자 수	0 은 주자 없음, 3 은 만루(풀 베이스)
base_state	주자가 어느 베이스에 있는지를 하나의 코드로 표시	12_ 이면 1·2루에 주자가 있다는 뜻
home_win_expectancy	현재 상황에서 홈팀이 경기를 이길 것으로 예상되는 확률	70 이면 홈팀 기대 승률이 70%
away_win_expectancy	현재 상황에서 원정팀이 이길 것으로 예상되는 확률	30 이면 원정팀 기대 승률이 30%
li	현재 투구가 경기 승패에 얼마나 중요한지를 나타내는 지표	값이 클수록 현재 투구 결과가 승패에 미치는 영향이 큼

home_win_expectancy 와 away_win_expectancy 는 제구 성공 확률이 아니라 경기 승리 확률이다.

base_state 코드 읽는 방법

밑줄 _ 은 해당 베이스에 주자가 없다는 뜻이다.

코드	의미	초보자용 설명
__	주자 없음	모든 베이스가 비어 있음
1_	1루	1루에만 주자 존재
2	2루	2루에만 주자 존재
_3	3루	3루에만 주자 존재
12_	1·2루	1루와 2루에 주자 존재
1_3	1·3루	1루와 3루에 주자 존재
_23	2·3루	2루와 3루에 주자 존재
123	만루	모든 베이스에 주자 존재

3. 결측치 및 데이터 무결성 검사

8개 변수 모두 결측치가 한 건도 없었다.

검사 항목	결과
주자 관련 변수 결측	0건
기대 승률 변수 결측	0건
li 결측	0건
주자 여부가 0·1 이외인 행	0건
num_runners_on 이 0~3을 벗어난 행	0건
주자 여부 합계와 num_runners_on 이 다른 행	0건
주자 여부와 base_state 가 일치하지 않는 행	0건

다음 관계가 모든 행에서 성립한다.

```
num_runners_on
= runner_on_1b + runner_on_2b + runner_on_3b
```

또한 base_state 는 세 주자 여부 변수를 문자로 표현한 값이다. 따라서 주자 관련 5개 변수는 서로 다른 정보가 아니라 동일한 주자 상황을 여러 방식으로 표현한 것이다.

4. 주자 출루 현황

4.1 베이스별 주자 존재 비율

베이스	주자 있음	전체 비율	주자 없을 때 제구 성공률	주자 있을 때 제구 성공률
1루	516,802건	35.04%	52.38%	52.37%
2루	319,768건	21.68%	52.42%	52.22%
3루	164,662건	11.16%	52.35%	52.56%

베이스별 주자 존재 여부에 따른 제구 성공률 차이는 약 0.2%p 이내로 매우 작았다. 따라서 “주자가 있으면 투수의 제구가 크게 나빠진다”는 단순한 관계는 확인되지 않았다.

4.2 출루 주자 수 분포

주자 수	투구 수	전체 비율	제구 성공률
0명	777,248	52.69%	52.30%
1명	442,864	30.02%	52.60%
2명	206,572	14.00%	52.34%
3명	48,408	3.28%	51.61%


전체 투구의 절반 이상은 주자가 없는 상황에서 발생했다. 만루 상황은 전체의 3.28%로 가장 적었으며 제구 성공률도 51.61%로 가장 낮았다.

다만 주자 수가 증가할수록 제구 성공률이 계속 감소하는 단조로운 관계는 나타나지 않았다.

5. 주자 배치별 분포와 타깃 관계

주자 상황	투구 수	전체 비율	제구 성공률
주자 없음 <u> </u>	777,248	52.69%	52.30%
1루 <u>1_</u>	293,724	19.91%	52.53%
2루 <u>_2_</u>	113,627	7.70%	52.49%
3루 <u>_ _3</u>	35,513	2.41%	53.61%
1·2루 <u>12_</u>	125,831	8.53%	52.13%
1·3루 <u>1_3</u>	48,839	3.31%	52.79%
2·3루 <u>_23</u>	31,902	2.16%	52.49%
만루 <u>123</u>	48,408	3.28%	51.61%

주자 배치별 제구 성공률



현재 투구 직전의 base_state에 따른 평균 제구 성공률입니다. (전체 평균은 52.38%이며, 차이를 확인하기 위해 축 범위를 50~54%로 제한했습니다.)

3루에만 주자가 있는 상황의 제구 성공률이 53.61%로 가장 높고, 만루가 51.61%로 가장 낮았다. 두 상황의 차이는 약 1.99%p이다.

그러나 이 차이가 주자 배치 자체의 인과효과라고 단정할 수는 없다. 주자 상황에는 다음 변수들이 함께 영향을 미치기 때문이다.

- 이닝
- 아웃카운트
- 볼·스트라이크 카운트
- 점수 차이
- 투수와 타자의 능력
- 시즌과 경기 유형

따라서 `base_state`는 단독 변수보다 다른 경기 상황 변수와 결합했을 때 의미가 있을 가능성이 높다.

6. 기대 승률 및 니 기술통계

컬럼	평균	표준편차	최소	Q1	중앙값	Q3	상위 1%
<code>home_win_expectancy</code>	50.27	30.27	0	25.60	52.20	74.30	98
<code>away_win_expectancy</code>	49.73	30.27	0	25.70	47.80	74.40	98
<code>li</code>	0.982	0.892	0	0.40	0.80	1.32	2.6

기대 승률 해석

홈팀과 원정팀의 기대 승률 합은 반올림 오차를 제외하면 약 100이다.

```
home_win_expectancy + away_win_expectancy ≈ 100
```

실제 합계는 99.9~100.1 범위였으며 두 변수의 상관계수는 -0.9999998이다. 따라서 사실상 동일한 정보를 반대 방향으로 표현한 변수다.

모델에는 두 변수 중 하나만 사용하거나, 투수 소속 팀 기준 기대 승률로 변환하는 것이 적절하다.

`li` 해석

`li`는 현재 투구 상황의 중요도를 나타내는 지표다.

- 경기 초반의 큰 점수 차: 낮은 `li`
- 경기 후반의 접전 상황: 높은 `li`
- 동점 또는 근소한 점수 차에서 득점권 주자 존재: 매우 높은 `li`

이 데이터의 평균은 0.982이고 중앙값은 0.80이다. 전체 투구의 95%는 `li ≤ 2.63`, 99%는 `li ≤ 4.37`이며 최댓값은 10.83이다.

높은 `li` 값은 오류나 단순 이상치가 아니라 실제로 매우 중요한 경기 상황일 수 있으므로 임의로 제거하면 안 된다.

7. LI 구간별 제구 성공률

LI 구간	투구 수	전체 비율	평균 LI	제구 성공률
≤0.5	486,739	33.00%	0.22	51.69%
0.5~1.0	450,724	30.56%	0.77	52.71%
1.0~2.0	388,241	26.32%	1.42	52.90%
2.0~3.0	99,041	6.71%	2.40	52.49%
>3.0	50,347	3.41%	4.08	51.81%

LI와 타깃의 단순 피어슨 상관계수는 0.004로 거의 0이다. 하지만 구간별로 확인하면 중간 수준인 1.0~2.0에서 제구 성공률이 가장 높고, 매우 낮거나 높은 구간에서는 상대적으로 낮아지는 비선형 관계가 나타난다.

따라서 LI를 단순 선형 변수로만 사용하면 이러한 관계를 충분히 반영하지 못할 수 있다.

8. 기대 승률과 제구 성공률의 관계

홈팀 기대 승률과 타깃의 단순 상관계수는 약 0.0005로 거의 0이다. 이는 홈팀 기대 승률이 항상 현재 투수에게 유리한 확률을 의미하지 않기 때문이다.

- 초 공격: 홈팀이 수비하므로 투수는 홈팀 소속
- 말 공격: 원정팀이 수비하므로 투수는 원정팀 소속

따라서 다음과 같이 투수 소속 팀 기준 기대 승률을 만드는 것이 더 적절하다.

```
pitcher_team_win_expectancy = np.where(
    top_bottom == "T",
    home_win_expectancy,
    away_win_expectancy
)
```

투수팀 기대 승률을 기준으로 구간을 나누면 다음 경향이 나타났다.

- 하위 10% 구간: 제구 성공률 50.67%
- 기대 승률 약 50% 구간: 제구 성공률 53.12%
- 상위 10% 구간: 제구 성공률 51.91%

즉, 승패가 어느 정도 결정된 극단적인 상황보다 승부가 비슷한 구간에서 제구 성공률이 상대적으로 높았다. 다만 시즌·이닝·경기 유형 등의 영향이 섞여 있으므로 인과관계로 해석하면 안 된다.

9. 변수 중복과 모델링 주의사항

9.1 주자 관련 변수

다음 변수들은 동일한 주자 상황을 중복 표현한다.

```
runner_on_1b
runner_on_2b
runner_on_3b
num_runners_on
base_state
```

특히 다음 관계가 정확히 성립한다.

```
num_runners_on
= runner_on_1b + runner_on_2b + runner_on_3b
```

따라서 선형·로지스틱 모델에 주자 여부 3개와 num_runners_on을 동시에 넣으면 완전 다중공선성이 발생한다.

다음 중 하나의 방식을 선택하는 것이 적절하다.

- 방법 A: base_state를 범주형 변수로 사용
- 방법 B: 1·2·3루 주자 여부 3개만 사용

- 방법 C: 주자 여부와 파생변수를 사용하고 `base_state`, `num_runners_on` 제외

트리 계열 모델에서는 모두 사용할 수 있지만 정보 중복으로 변수 중요도가 분산될 수 있으므로 제거 전후 성능을 비교하는 것이 좋다.

9.2 기대 승률 변수

`home_win_expectancy`와 `away_win_expectancy`는 사실상 완전한 보완 관계이므로 두 변수를 동시에 사용할 필요가 없다.

가장 추천하는 방법은 두 원본 대신 `pitcher_team_win_expectancy`를 사용하는 것이다.

9.3 `li`

`li`는 오른쪽 꼬리가 긴 분포이므로 다음 방법을 비교할 수 있다.

```
log_li = np.loglp(li)
```

- 원본 `li`
- `loglp(li)`
- 구간화된 `li`
- 트리 모델에 원본값 사용

10. 추천 파생변수

```
# 득점권 주자 여부: 2루 또는 3루에 주자가 있는 경우
runner_in_scoring_position = (
    (runner_on_2b == 1) | (runner_on_3b == 1)
).astype(int)

# 득점권 주자 수
num_runners_in_scoring_position = (
    runner_on_2b + runner_on_3b
)

# 만루 여부
bases_loaded = (num_runners_on == 3).astype(int)

# 투수팀 기준 기대 승률
pitcher_team_win_expectancy = np.where(
    top_bottom == "T",
    home_win_expectancy,
    away_win_expectancy
)

# LI 로그 변환
log_li = np.loglp(li)

# 득점권과 중요도의 상호작용
scoring_position_li = (
    runner_in_scoring_position * li
)
```

파생변수는 모두 현재 투구 직전 정보만 사용하므로 평가 데이터 독립성 원칙에도 위배되지 않는다.