



4번 EDA

1. 분석 대상

본 분석에서는 `train.csv` 의 1,475,092개 투구를 대상으로 다음 10개 변수를 살펴보았다.

`asof` 변수는 모두 현재 투구 직전까지 집계된 과거 기록이다. 따라서 현재 투구의 결과, 실제 구종 또는 투구 위치는 포함하지 않는다. 전체 학습 데이터의 제구 성공률은 52.38%이며, 총 792명의 투수가 포함되어 있다.

2. 컬럼 상세 소개

구분	컬럼	측정 내용	값이 높을 때의 의미	EDA·모델링 주의점
누적량	<code>asof_pitcher_n</code>	투수의 누적 투구 수	과거 표본이 많아 누적 통계의 신뢰도가 높음	실력보다 표본 신뢰도를 나타내며 오른쪽 꼬리가 긴 분포
제구	<code>asof_pitcher_success_rate</code>	과거 누적 제구 성공률	전반적인 제구 성공 경험 많음	담당 변수 중 타깃과 가장 강한 양의 관계
제구	<code>asof_pitcher_reverse_rate</code>	의도 반대성 투구 비율	의도한 방향과 다르게 투구한 비율이 높음	성공률과 강한 음의 상관관계
제구	<code>asof_pitcher_middle_rate</code>	가운데·위험 코스 투구 비율	가운데 또는 위험 코스로 간 투구가 많음	제구 실패와 완전히 동일한 개념은 아님
결과	<code>asof_pitcher_ball_rate</code>	불성 결과 비율	불성 결과가 많음	<code>control_success=0</code> 과 동일한 개념은 아님
결과	<code>asof_pitcher_strike_rate</code>	스트라이크성 결과 비율	스트라이크성 결과가 많음	스트라이크성 결과가 반드시 제구 성공을 의미하지는 않음
구종량	<code>asof_pitcher_pitchmix_n</code>	구종 비율 계산에 사용된 표본 수	구종 구성 통계의 신뢰도가 높음	실제 데이터에서는 <code>asof_pitcher_n</code> 과 완전히 동일
구종	<code>asof_pitcher_fastball_rate</code>	fastball 계열 사용 비율	빠른 공 계열 사용 성향이 높음	현재 투구의 구종이 아닌 과거 구종 성향
구종	<code>asof_pitcher_breaking_rate</code>	breaking 계열 사용 비율	슬라이더·커브 등 변화구 성향이 높음	세 구종군 비율의 합이 1
구종	<code>asof_pitcher_offspeed_rate</code>	offspeed 계열 사용 비율	체인지업 계열 사용 성향이 높음	사용 빈도가 낮은 투수는 0에 가까울 수 있음

3. 누적 표본 수 기술통계

컬럼	유효 표본	평균	표준편차	최소	Q1	중앙값
<code>asof_pitcher_n</code>	1,475,092	2,661.32	2,690.01	0	684	1,776
<code>asof_pitcher_pitchmix_n</code>	1,475,092	2,661.32	2,690.01	0	684	1,776

전체 관측치 중 가운데 50%는 누적 투구 수가 684~3,725구 사이에 위치한다.

평균은 2,661구로 중앙값 1,776구보다 높다. 이는 일부 투수의 누적 투구 수가 매우 많아 분포가 오른쪽으로 길게 늘어져 있음을 의미한다. 모델에서는 원본값과 함께 다음 로그 변환을 고려할 수 있다.

```
log_pitcher_n=np.log1p(asof_pitcher_n)
```

두 표본 수 변수는 전체 1,475,092행에서 값이 완전히 동일하므로 하나만 사용해도 정보 손실이 없다.

4. 비율 변수 기술통계

아래 수치는 비율을 백분율로 변환한 값이며, 표준편차의 단위는 `%p` 이다.

컬럼	평균	표준편차	최소	Q1	중앙값	Q3	최대
<code>success_rate</code>	53.52%	6.18%p	0%	49.91%	53.20%	56.90%	100%

컬럼	평균	표준편차	최소	Q1	중앙값	Q3	최대
reverse_rate	21.52%	6.07%p	0%	17.89%	21.80%	25.11%	100%
middle_rate	14.19%	3.18%p	0%	12.56%	14.19%	15.70%	100%
ball_rate	37.22%	4.18%p	0%	34.81%	36.94%	39.22%	100%
strike_rate	44.19%	3.96%p	0%	42.31%	44.23%	46.24%	100%
fastball_rate	55.44%	9.91%p	0%	48.65%	54.40%	61.36%	100%
breaking_rate	28.93%	10.83%p	0%	21.59%	28.93%	36.18%	100%
offspeed_rate	15.63%	10.85%p	0%	7.50%	14.06%	21.70%	100%

모든 비율은 정상 범위인 0~1 사이에 존재한다. 일부 행에서 0% 또는 100%가 나타나지만, 누적 투구 수가 1~2개인 초기 시점에는 자연스럽게 발생할 수 있다.

따라서 이러한 값을 단순 이상치로 판단해 제거하기보다는 누적 표본 수를 함께 사용하거나 smoothing을 적용해야 한다.

5. 결측치 구조

8개 비율 변수는 모두 정확히 792건의 결측치를 가진다.

- 전체 대비 결측률: 0.054%
- 전체 투수 수: 792명
- asof_pitcher_n=0 인 행: 792건
- 누적 투구 수가 0인 행에서 8개 비율이 모두 결측
- 누적 투구 수가 1 이상이면서 비율이 결측인 행: 0건

따라서 결측치는 데이터 오류가 아니라 각 투수가 처음 등장한 cold-start 상태로 판단된다.

모델에서는 결측치를 단순히 0으로 대체하기보다 전체 또는 그룹별 사전확률로 대체하고 cold-start 여부를 별도 변수로 생성하는 것이 적절하다.

```
pitcher_cold_start= (asof_pitcher_n==0).astype(int)
```

6. 변수 간 중복 및 구성 관계

6.1 누적 표본 수 중복

```
asof_pitcher_n = asof_pitcher_pitchmix_n
```

두 변수는 전체 행에서 완전히 동일하다. 다중공선성과 불필요한 중복을 줄이기 위해 하나만 사용하는 것이 적절하다.

6.2 구종 비율의 합

```
fastball_rate + breaking_rate + offspeed_rate ≈ 1
```


세 구종 비율의 합은 반올림 오차를 제외하면 1이다. 따라서 선형·로지스틱 모델에서는 세 변수 중 하나를 제외해야 한다. 트리 계열 모델에서도 정보 중복을 줄이기 위해 하나를 제거할 수 있다.

6.3 주요 변수 간 상관관계

변수 조합	상관계수	해석
success_rate ↔ reverse_rate	-0.810	제구 성공률이 높을수록 의도 반대성 비율이 낮은 경향
ball_rate ↔ strike_rate	-0.773	불성 결과가 많을수록 스트라이크성 결과가 적은 경향
pitcher_n ↔ pitchmix_n	1.000	완전히 동일한 중복 변수

다만 success_rate, reverse_rate, middle_rate 는 합이 1이 아니므로 서로 완전히 배타적인 결과로 해석하면 안 된다.

7. 타깃과의 단순 상관관계



변수	피어슨 상관계수
asof_pitcher_success_rate	+0.0843
asof_pitcher_reverse_rate	-0.0795
asof_pitcher_middle_rate	-0.0361
asof_pitcher_ball_rate	-0.0177
asof_pitcher_offspeed_rate	+0.0138
asof_pitcher_breaking_rate	-0.0136
asof_pitcher_n	-0.0116
asof_pitcher_pitchmix_n	-0.0116
asof_pitcher_strike_rate	+0.0039
asof_pitcher_fastball_rate	-0.0002

분석 결과, `success_rate`가 담당 변수 중 타깃과 가장 강한 양의 관계를 보였고 `reverse_rate`는 가장 강한 음의 관계를 보였다.

누적 성공률 하위 10% 집단의 실제 제구 성공률은 45.68%, 상위 10% 집단은 61.23%로 나타났다. 따라서 `success_rate`는 투수의 기본적인 제구 능력을 나타내는 핵심 변수로 판단할 수 있다.

단, 위 결과는 전체 학습 데이터에서 계산한 단순 상관관계이므로 인과관계나 시간순 검증 성능을 의미하지 않는다.

8. 종합 결론

담당 변수 10개의 EDA 결과는 다음과 같이 정리할 수 있다.

1. `asof_pitcher_success_rate`와 `asof_pitcher_reverse_rate`가 타깃과 가장 뚜렷한 관계를 보였다.
2. 비율 변수의 결측 792건은 오류가 아니라 투수별 최초 등장에 따른 cold-start이다.
3. `asof_pitcher_n`과 `asof_pitcher_pitchmix_n`은 완전히 중복되므로 하나만 사용한다.
4. 구종 비율 세 변수는 합이 1이므로 구성비 자료라는 점을 고려해야 한다.
5. 누적 표본이 적은 구간의 0%·100% 극단값은 제거하지 않고 smoothing을 적용한다.
6. 구종 비율은 단독 효과보다 투수·타자 손잡이, 카운트, 경기 상황과 결합했을 때 유용할 가능성이 높다.

별첨(변수 추가 해석)

1. `asof_pitcher_n`

투수의 실력을 직접 나타내는 변수라기보다 과거 통계가 얼마나 신뢰할 만한지를 보여주는 변수다.

예를 들어 다음 두 투수의 과거 제구 성공률이 모두 60%라고 하더라도 신뢰도는 다르다.

- 투수 A: 5구 중 3구 성공 → 60%
- 투수 B: 1,000구 중 600구 성공 → 60%

두 투수의 성공률은 같지만, 투수 B의 60%가 훨씬 안정적인 기록이다. 따라서 비율 변수는 반드시 누적 투구 수와 함께 해석해야 한다.

2. `asof_pitcher_success_rate`

투수의 전반적인 제구 능력을 가장 직접적으로 보여주는 과거 기록이다.

다만 현재 투구의 성공 여부가 아니라 과거 누적 성공률이므로, 이 값이 60%라고 해서 현재 투구도 반드시 성공하는 것은 아니다. 투수의 기본 제구 능력을 나타내는 사전 정보로 이해하면 된다.

3. asof_pitcher_reverse_rate

공이 투수의 의도와 반대 방향으로 간 비율이다.

예를 들어 포수나 투수가 몸쪽 코스를 의도했지만 공이 바깥쪽으로 빠지는 경우가 해당할 수 있다. 이 비율이 높으면 원하는 방향으로 공을 보내는 능력이 상대적으로 불안정할 가능성이 있다.

실제 데이터에서도 `success_rate`와 `reverse_rate`의 상관계수는 -0.810으로 나타났다. 즉, 과거 제구 성공률이 높은 투수일수록 의도 반대 성 투구 비율은 낮은 경향이 있다.

4. asof_pitcher_middle_rate

공이 스트라이크존 가운데 또는 타자가 치기 좋은 위험한 위치로 간 비율이다.

가운데로 간 공이 항상 제구 실패인 것은 아니지만, 일반적으로 타자가 치기 쉬운 코스가 될 수 있다. 따라서 이 값이 높으면 제구 안정성 측면에서 부정적인 신호가 될 가능성이 있다.

5. asof_pitcher_ball_rate

과거 투구 중 볼성 결과가 나타난 비율이다.

하지만 볼이 많다고 해서 반드시 제구력이 나쁘다는 의미는 아니다. 투수는 타자를 속이기 위해 의도적으로 스트라이크존 밖에 공을 던지기도 한다. 따라서 `ball_rate`는 제구 실패율이 아니라 과거 투구 결과의 성격을 보여주는 변수로 보는 것이 정확하다.

6. asof_pitcher_strike_rate

과거 투구 중 스트라이크성 결과가 나타난 비율이다.

스트라이크가 많더라도 반드시 제구 성공률이 높은 것은 아니다. 포수가 바깥쪽을 요구했는데 공이 가운데로 몰려 스트라이크가 된 경우에는 스트라이크성 결과이면서 제구에는 실패할 수 있다.

따라서 다음 두 변수는 서로 다른 개념이다.

- `strike_rate`: 스트라이크성 결과가 얼마나 많았는가
- `success_rate`: 의도한 제구에 얼마나 성공했는가

7. asof_pitcher_pitchmix_n

구종 비율을 계산하는 데 사용된 과거 투구 수다. 개념적으로는 구종 통계의 표본 수이지만, 이번 데이터에서는 `asof_pitcher_n`과 모든 행에서 동일하다.

따라서 두 변수를 모델에 동시에 넣을 필요는 없다.

8. fastball_rate, breaking_rate, offspeed_rate

이 세 변수는 투수가 과거에 어떤 종류의 공을 주로 던졌는지를 나타낸다.

- `fastball`: 직구 계열의 빠른 공
- `breaking`: 슬라이더·커브 등 움직임이 큰 변화구 계열
- `offspeed`: 체인지업 등 속도 차이로 타이밍을 빼앗는 계열

예를 들어 구종 비율이 다음과 같다면:

```
fastball_rate = 0.55
breaking_rate = 0.30
offspeed_rate = 0.15
```

해당 투수가 과거에 빠른 공 계열 55%, breaking 계열 30%, offspeed 계열 15%를 사용했다는 의미다.

세 비율의 합은 1이지만, 현재 투구에서 어떤 구종을 던졌는지를 의미하지는 않는다. 해당 투수의 전반적인 구종 선택 성향을 보여주는 과거 정보다.